Proyecto parte 1

1. Google Play Store apps and reviews

Las aplicaciones móviles están en todas partes. Son fáciles de crear y pueden resultar muy lucrativas. Debido a estos dos factores, se están desarrollando cada vez más aplicaciones. En este ejercicio, haremos un análisis completo del mercado de aplicaciones de Android comparando más de diez mil aplicaciones en Google Play en diferentes categorías. Buscaremos información valiosa en los datos para diseñar estrategias que impulsen el crecimiento y la retención.

Tenemos dos fuentes de datos:

- `apps.csv` : contiene todos los detalles de las aplicaciones en Google Play. Hay 13 características que describen una aplicación determinada.
- `user_reviews.csv` : contiene 100 reseñas para cada aplicación, reviews. El texto de cada reseña se ha procesado previamente y se le atribuyen tres características nuevas: Sentimiento (positivo, negativo o neutral), Polaridad del sentimiento y Subjetividad del sentimiento..

```
# Importa las librerías de pandas y matplotlin
import pandas as pd
import matplotlib.pyplot as plt

# Importa el datase apps.csv
apps = pd.read_csv("apps.csv")

# Borra todos los duplicados del dataset
apps = apps.drop_duplicates()

# Imprime el total de apps que se van a analizar que quedan (dimensión)
print('Total number of apps in the dataset = ', apps.shape[0])

# Imprime la estádistica descriptiva de resumen
print(apps.describe())

# Vamos a echar un vistazo al DataFrame final
print(apps)
```

```
Total number of apps in the dataset =  9659
            Rating       Reviews         Size
count  8196.000000  9.659000e+03  8432.000000
mean      4.173243  2.165926e+05    20.395327
std       0.536625  1.831320e+06    21.827509
min       1.000000  0.000000e+00     0.000000
25%       4.000000  2.500000e+01     4.600000
50%       4.300000  9.670000e+02    12.000000
75%       4.500000  2.940100e+04    28.000000
max       5.000000  7.815831e+07   100.000000
                                                   App             Category  \
0        Photo Editor & Candy Camera & Grid & ScrapBook       ART_AND_DESIGN
1                                   Coloring book moana       ART_AND_DESIGN
2     U Launcher Lite – FREE Live Cool Themes, Hide ...       ART_AND_DESIGN
3                                 Sketch - Draw & Paint       ART_AND_DESIGN
4                 Pixel Draw - Number Art Coloring Book       ART_AND_DESIGN
...                                                 ...                  ...
9654                                   Sya9a Maroc - FR               FAMILY
9655                   Fr. Mike Schmitz Audio Teachings               FAMILY
9656                            Parkinson Exercices FR              MEDICAL
9657                      The SCP Foundation DB fr nn5n  BOOKS_AND_REFERENCE
9658      iHoroscope - 2018 Daily Horoscope & Astrology            LIFESTYLE

      Rating  Reviews  Size     Installs  Type Price Content Rating  \
0        4.1      159  19.0      10,000+  Free     0       Everyone
1        3.9      967  14.0     500,000+  Free     0       Everyone
2        4.7    87510   8.7   5,000,000+  Free     0       Everyone
3        4.5   215644  25.0  50,000,000+  Free     0           Teen
4        4.3      967   2.8     100,000+  Free     0       Everyone
...      ...      ...   ...          ...   ...   ...            ...
9654     4.5       38  53.0       5,000+  Free     0       Everyone
9655     5.0        4   3.6         100+  Free     0       Everyone
9656     NaN        3   9.5       1,000+  Free     0       Everyone
9657     4.5      114   NaN       1,000+  Free     0     Mature 17+
9658     4.5   398307  19.0  10,000,000+  Free     0       Everyone

                        Genres      Last Updated         Current Ver  \
0                 Art & Design   January 7, 2018               1.0.0
1     Art & Design;Pretend Play  January 15, 2018               2.0.0
2                 Art & Design    August 1, 2018               1.2.4
3                 Art & Design      June 8, 2018  Varies with device
4       Art & Design;Creativity     June 20, 2018                 1.1
...                         ...               ...                 ...
9654                 Education     July 25, 2017                1.48
9655                 Education      July 6, 2018                   1
9656                   Medical  January 20, 2017                   1
9657          Books & Reference  January 19, 2015  Varies with device
9658                 Lifestyle     July 25, 2018  Varies with device

             Android Ver
0          4.0.3 and up
1          4.0.3 and up
2          4.0.3 and up
3            4.2 and up
4            4.4 and up
```

2. Data cleaning

Las cuatro variables con las que trabajaremos con más frecuencia de ahora en adelante son *Installs*, *Size*, *Rating* y *Price*. La función `info()` nos dice que las columnas *Installs* y *Price* son de tipo `object`, no son de tipo `int` o `float` como esperaríamos. Esto se debe a que la columna contiene algunos caracteres más que solo [0,9] dígitos. Idealmente, queremos que estas columnas fueran puramente numéricas

Por lo tanto, ahora necesitamos limpiar nuestros datos. Específicamente, los caracteres especiales `,` y `+` que se encuentran en la columna *Installs* y `$` que esta en la columna *Price*.

Aquí un link donde podrás ver un poco más a detalle que es una función lambda

```
# Lista de caracteres a eliminar
chars_to_remove = [",", "+", "$"]
# Lista de las columnas a limpiar
cols_to_clean = ["Installs", "Price"]

# Loop para cada columna
for col in cols_to_clean:
    # Loop para cada caracter especial
    for char in chars_to_remove:
        # Reemplaza con una función lambda el caracter especial por un texto vacío ('')
        apps[col] = apps[col].apply(lambda x: x.replace(char, ""))
    # Convierte la columna a tipo flotante (float)
    apps[col] = apps[col].astype(float)
```

3. Exploring App's categories

Con más de mil millones de usuarios activos en 190 países de todo el mundo, Google Play sigue siendo una importante plataforma de distribución para crear una audiencia global. Para que las empresas muestren sus aplicaciones a los usuarios, es importante hacerlas más rápida y fácilmente visibles en Google Play. Para mejorar la experiencia de búsqueda general, Google ha introducido el concepto de agrupar aplicaciones en categorías.

Esto nos lleva a las siguientes preguntas:

- ¿Qué categoría tiene la mayor participación de aplicaciones (activas) en el mercado?
- ¿Alguna categoría específica domina el mercado?
- ¿Qué categorías tienen la menor cantidad de aplicaciones?

Vamos a responder estas preguntas aquí `33` categorías unicas estan presentas en nuestro dataset. Las apps de *Family* y *Game* tienen la mayor prevalencia del mercado. Curiosamente, *Tools*, *Business* y *Medical* también están en el top.

```
# Imprime el total de categorías únicas
num_categories = len(apps["Category"].unique())
print('Number of categories = ', num_categories)

# Cuenta el número de aplicaciones en cada Categoría y ordena de manera descendente
num_apps_in_category = apps["Category"].value_counts()

# Muestra el resultado en una gráfica de barras
#fig, ax = plt.subplots()
plt.figure().set_figwidth(15)
plt.bar(num_apps_in_category.index, num_apps_in_category)
plt.tick_params(axis='x', labelrotation = 90)
plt.title("Gráfica de Barras")
def add_value_label(x_list, y_list):
    for i in range(len(x_list)):
        plt.text(i, y_list[i], y_list[i], ha="center")
add_value_label(num_apps_in_category.index, num_apps_in_category)
plt.show()

print("¿Qué categoría tiene la mayor participación de aplicaciones (activas) en el mercado?", "R = La categoría de Family.")
print("¿Alguna categoría específica domina el mercado?", "No precisamente, la categoría Family es la de mayor presencia con el 18.97% del total de aplic
print("¿Qué categorías tienen la menor cantidad de aplicaciones?", "R = El top 3 de las categorías con menor cantidad de aplicaciones son; Parenting, Co
```

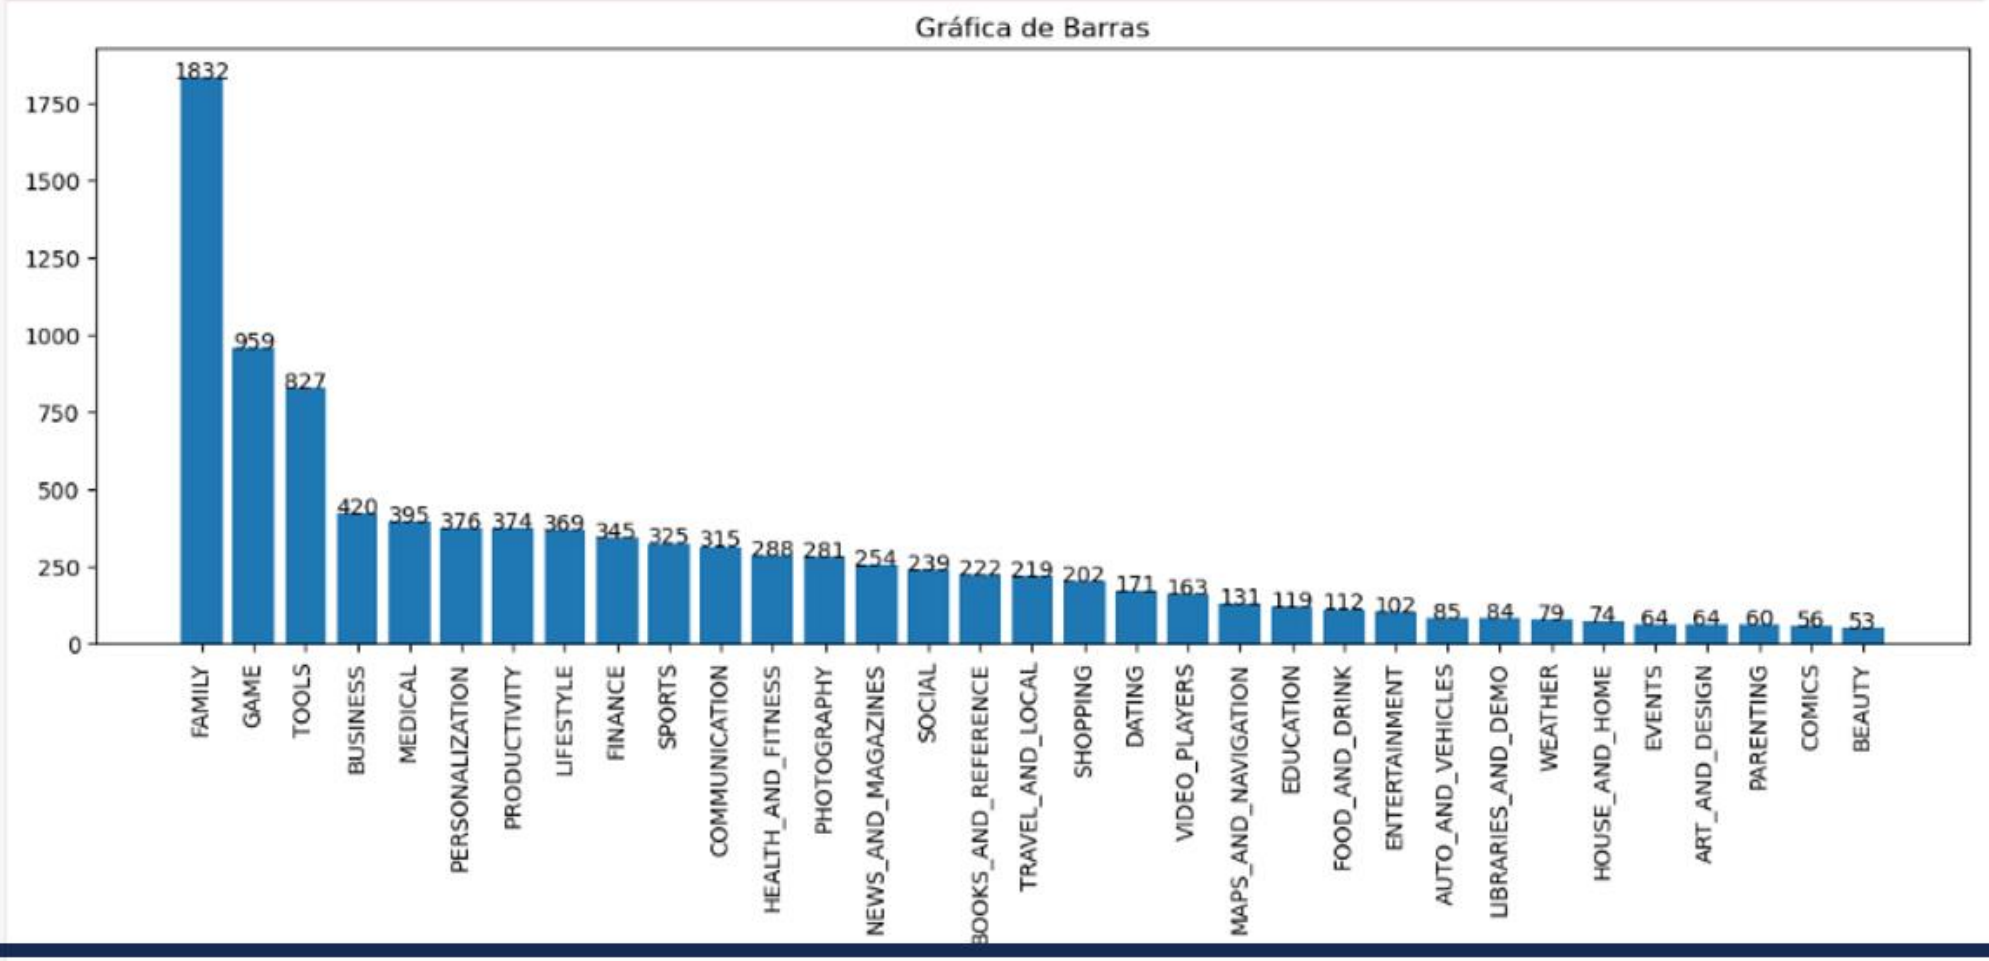

¿Qué categoría tiene la mayor participación de aplicaciones (activas) en el mercado? R = La categoría de Family.
¿Alguna categoría específica domina el mercado? No precisamente, la categoría Family es la de mayor presencia con el 18.97% del total de aplicaciones en el mercado.
¿Qué categorías tienen la menor cantidad de aplicaciones? R = El top 3 de las categorías con menor cantidad de aplicaciones son; Parenting, Comics y Beauty

4. Ratings Distribution

Después de analizar la participación de mercado para cada categoría de las aplicaciones, veamos cómo se posicionan de acuerdo a las calificaciones (en una escala del 1 al 5) las cuales afectan la imagen de la marca general de la empresa. Las calificaciones son un indicador clave de rendimiento de una aplicación.

```
# Calcular el promedio de calificación de las apps
avg_app_rating = apps["Rating"].mean()
print('Average app rating = ', avg_app_rating)

# Calcula el promedio de calificación por categoría
avg_rating_per_category = apps.groupby("Category").mean(numeric_only=True)["Rating"]

# Visualiza en un histograma el comportamiento del Rating
plt.hist(avg_rating_per_category)
plt.title("Histograma")
plt.xlabel("Promedio de Calificaciones")
plt.ylabel("Frecuencia")
plt.show()
```

```
Average app rating =  4.173243045387994
```

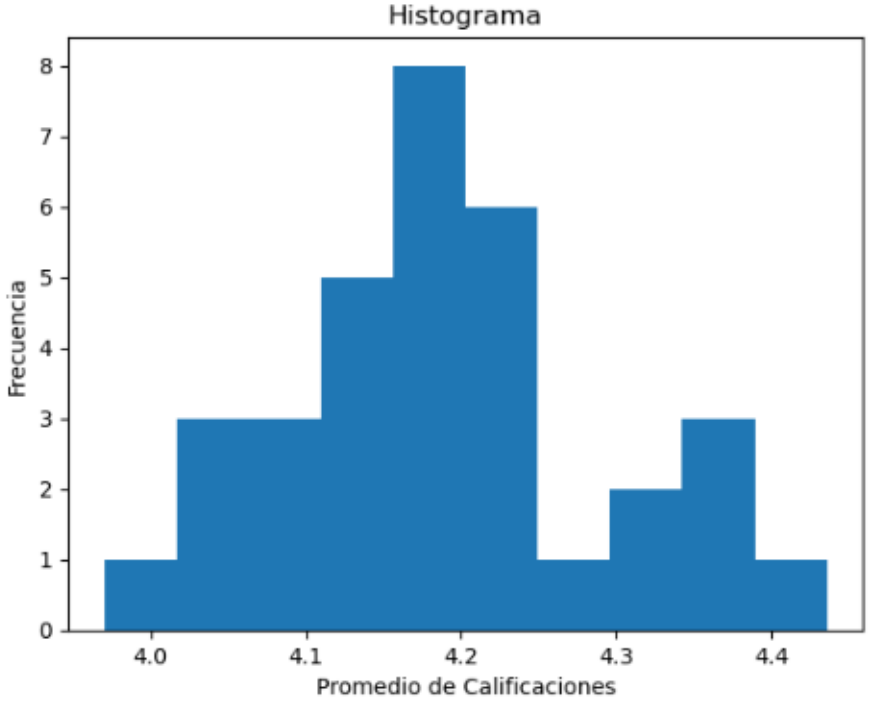

5. Size and Price

Examinemos ahora el tamaño y el precio de la aplicación. En cuanto al tamaño, si la aplicación móvil es demasiado grande, puede ser difícil y/o costoso para los usuarios descargarla. Los tiempos de descarga prolongados pueden desanimar a los usuarios incluso antes de que experimenten su aplicación móvil. Además, el dispositivo de cada usuario tiene una cantidad limitada de espacio en disco. Por el precio, algunos usuarios esperan que sus aplicaciones sean gratuitas o económicas. Estos problemas se agravan si el mercado objetivo es en países en vías de desarrollo; especialmente debido a las velocidades de Internet, el poder adquisitivo, los tipos de cambio, etc.

How can we effectively come up with strategies to size and price our app?

- ¿El tamaño de una aplicación afecta su calificación?
- ¿Los usuarios realmente se preocupan por las aplicaciones pesadas del sistema o prefieren las aplicaciones ligeras?
- ¿El precio de una aplicación afecta su calificación?
- ¿Los usuarios siempre prefieren las aplicaciones gratuitas a las de paga?

```
import seaborn as sns
import warnings
warnings.filterwarnings("ignore")

sns.set_style("darkgrid")

# Filtra filas donde los valores de 'Rating' y 'Size' no sean nulos
apps_with_size_and_rating_present = apps.dropna(subset = ["Rating", "Size"])

# Filtra las categorías con al menos 250 apps
large_categories = apps_with_size_and_rating_present.groupby("Category").filter(lambda x: len(x) >= 250)

# Gráfica size vs. rating
plt1 = sns.jointplot(x = large_categories["Size"], y = large_categories["Rating"])

# Selecciona las apps de paga 'Type' = 'Paid'
paid_apps = large_categories[large_categories["Type"] == "Paid"]

# Grafica price vs. rating de las paplicaciones de paga
plt2 = sns.jointplot(x = paid_apps["Price"], y = paid_apps["Rating"])
plt.show()

print("¿El tamaño de una aplicación afecta su calificación?", "R = Se observa que las medias de calificación se comportan igual independientemente del t
print("¿Los usuarios realmente se preocupan por las aplicaciones pesadas del sistema o prefieren las aplicaciones ligeras?", "R = Si, ya que mientras me
print("¿El precio de una aplicación afecta su calificación?", "R = Si, ya que en los datos se observa que las aplicaciones con un costo por encima de lo
print("¿Los usuarios siempre prefieren las aplicaciones gratuitas a las de paga?", "R = No siempre, pero si hay considerablemente una mayor población de
```

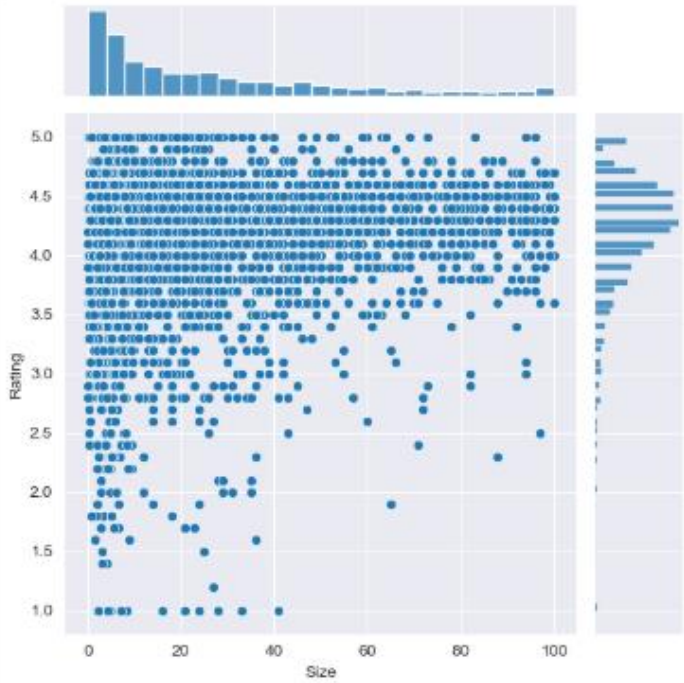
Rating
5.0
4.5
4.0
3.5
3.0
2.5
2.0
1.5
1.0
0
20
40
60
80
100
Size

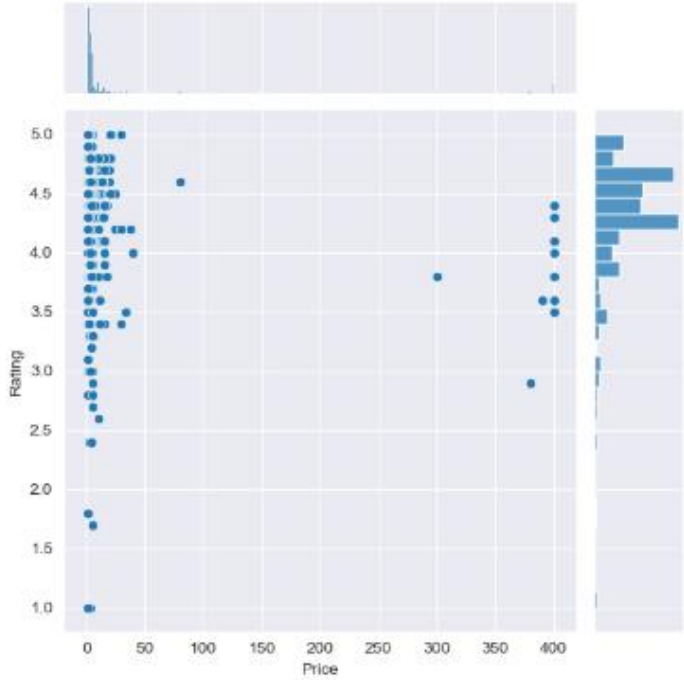
Rating
5.0
4.5
4.0
3.5
3.0
2.5
2.0
1.5
1.0
0
50
100
150
200
250
300
350
400
Price

```
¿El tamaño de una aplicación afecta su calificación? R = Se observa que las medias de calificación se comportan igual independientemente del tamaño de l
a aplicación, por lo que se podría deducir que no afceta. Sin embargo, cabe recalcar que en los casos donde las aplicaciones tiene  un costo bajo (menor
a 40) las calificaciones de 5.0 son mucho más frecuentes.
¿Los usuarios realmente se preocupan por las aplicaciones pesadas del sistema o prefieren las aplicaciones ligeras? R = Si, ya que mientras menor sea el
tamaño de la aplicación hay mayores población que las utiliza.
¿El precio de una aplicación afecta su calificación? R = Si, ya que en los datos se observa que las aplicaciones con un costo por encima de los $300 usd
no tiene calificaciones arriba de los 4.5.
¿Los usuarios siempre prefieren las aplicaciones gratuitas a las de paga? R = No siempre, pero si hay considerablemente una mayor población de usuarios
con apps gratuitas.
```

6. Relation between Category & Price

Así que ahora viene la parte difícil. ¿Cómo se supone que las empresas y los desarrolladores cubran sus cuotas de fin de mes? ¿Qué estrategias de monetización pueden utilizar las empresas para maximizar las ganancias? Los costos de las aplicaciones se basan en gran medida en las características, la complejidad y la plataforma. Hay muchos factores a considerar al seleccionar la estrategia de precios adecuada para las aplicaciones moviles. Es importante considerar la disposición de su cliente a pagar por la aplicación. Un precio elevado puede hacer que los clientes no se vean atraídos por descargarlaque ocurra la descarga o pueden eliminar una aplicación que han descargado después de recibir demasiados anuncios o simplemente no obtener el valor que esperaban de su dinero.

Las diferentes categorías exigen diferentes rangos de precios. Algunas aplicaciones que son simples y se usan a diario, como la aplicación de calculadora, probablemente deberían mantenerse gratuitas. Sin embargo, tendría sentido cobrar por una aplicación médica altamente especializada que diagnostica a pacientes diabéticos, así que vamos a descubrir y encontrar la respuesta

```
import matplotlib.pyplot as plt
fig, ax = plt.subplots()
fig.set_size_inches(15, 8)

# Lista de categorías populares
popular_app_cats = apps[apps.Category.isin(['GAME', 'FAMILY', 'PERSONALIZATION',
                                            'MEDICAL', 'TOOLS', 'PRODUCTIVITY',
                                            'LIFESTYLE','BUSINESS'])]

# Examina la tendencia de precio graficando el Precio por Categoría
ax = sns.stripplot(x = popular_app_cats["Category"], y = popular_app_cats["Price"], jitter=True, linewidth=1)
ax.set_title('App pricing trend across categories')

# Selecciona las apps con un precio mayor a 200
apps_above_200 = popular_app_cats[popular_app_cats["Price"] > 200]
print(apps_above_200[['Category', 'App', 'Price']])
print("")
print("Inferencias: Los resultados muestran que las aplicaciones de estilo de vida y familiares, son las que pueden llegar a tener un precio alto (por e
```

	Category	App	Price
3327	FAMILY	most expensive app (H)	399.99
3465	LIFESTYLE	💎 I'm rich	399.99
3469	LIFESTYLE	I'm Rich - Trump Edition	400.00
4396	LIFESTYLE	I am rich	399.99
4398	FAMILY	I am Rich Plus	399.99
4399	LIFESTYLE	I am rich VIP	299.99
4401	LIFESTYLE	I am extremely Rich	379.99
4406	FAMILY	I Am Rich Pro	399.99
4410	FAMILY	I Am Rich	389.99
8780	LIFESTYLE	I'm Rich/Eu sou Rico/أنا غني/我很有钱	399.99

Inferencias: Los resultados muestran que las aplicaciones de estilo de vida y familiares, son las que pueden llegar a tener un precio alto (por encima de los $300.00 usd). Por otro lado, las aplicaciones referentes a negocios, médicas y de productividad, pudieran dependiendo la eficiencia y aceptación de la app, valorarse por encima de los $50.00 usd.

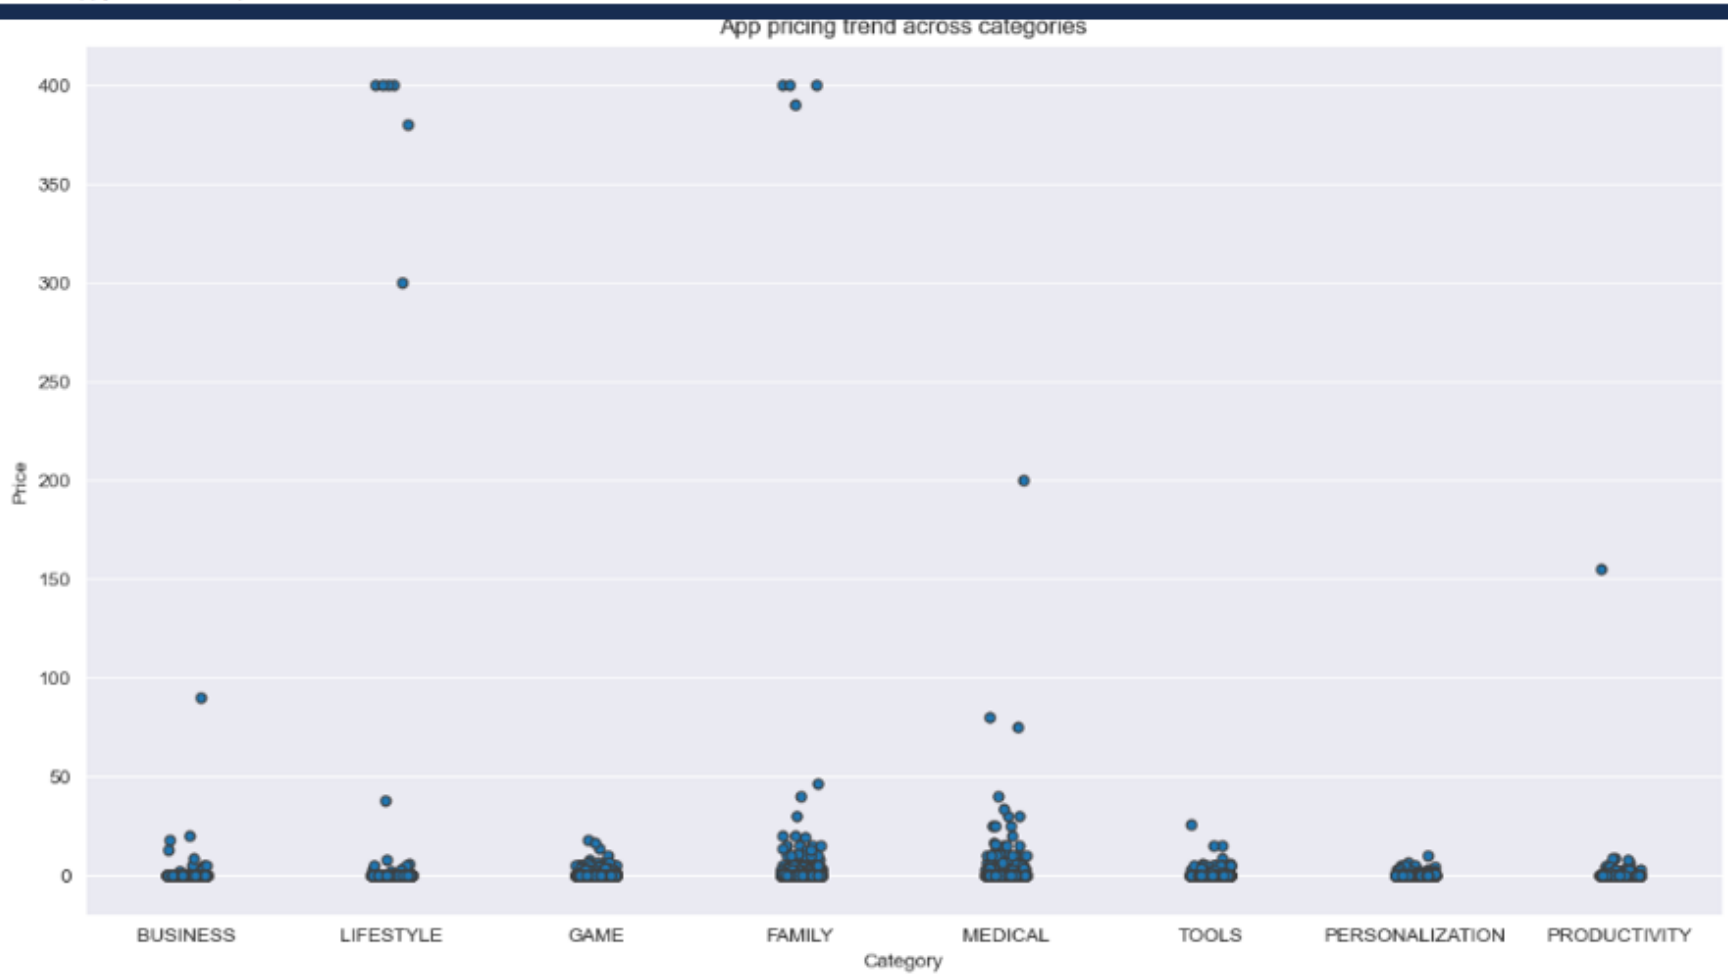

7. Paid apps vs Free apps

Para las aplicaciones de Play Store en la actualidad, existen cinco tipos de estrategias de precios: gratis, "freemium", de pago, "paymium" y de suscripción. Centrémonos solo en aplicaciones gratuitas y de pago.

Algunas características de las aplicaciones gratuitas son:

- Libres de descarga.
- La principal fuente de ingresos a menudo proviene de la publicidad.
- Por lo general son creadaa por empresas que tienen otros productos y la aplicación sirve como una extensión de esos productos.
- Puede servir como una herramienta para la retención de clientes, la comunicación y el servicio al cliente.

Algunas características de las aplicaciones de paga son:

- Tienen un tiempo de servicio de prueba gratuito, esto para que el usuario pueda conocerla.
- Ofrecen un servicio de mayor especialidad.

¿Además de esto que otras características diferencías a las aplicaciones de pago las aplicaciones gratuitas?

```
type_apps = apps[apps["Type"].isin(["Free", "Paid"])]
type_apps

type_apps['Last Updated'] = pd.to_datetime(type_apps['Last Updated'])
n = len(type_apps[type_apps['Type'] == "Paid"])
muestra_free = type_apps[type_apps['Type'] == "Free"].sample(n)
muestra_paid = type_apps[type_apps['Type'] == "Paid"]
muestra_final = pd.concat([muestra_free, muestra_paid])

fig, axes = plt.subplots(nrows=1, ncols=3, figsize=(20, 8))
sns.violinplot(data = type_apps, y = "Size", x = "Type", palette = "Set1", ax=axes[0])
sns.stripplot(data = type_apps, y = "Installs", x = "Type", palette = "Set1", ax=axes[1])
sns.stripplot(data = muestra_final, y = "Last Updated", x = "Type", alpha = 0.2, palette="Set1", ax=axes[2])
plt.show()

print("Luego de anaizar las diferentes características que nos ofrece la base de datos, entre otras de las diferencias que se pueden observar entre las
```

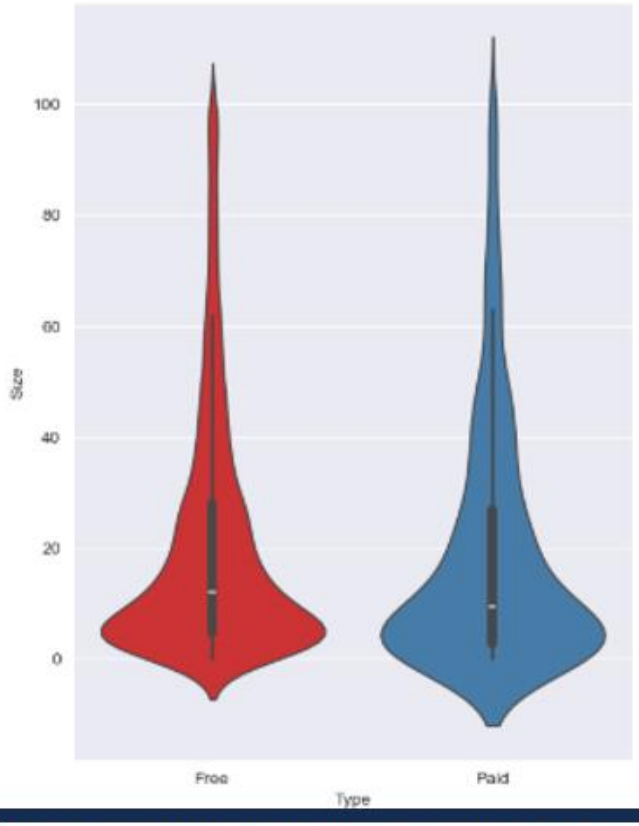

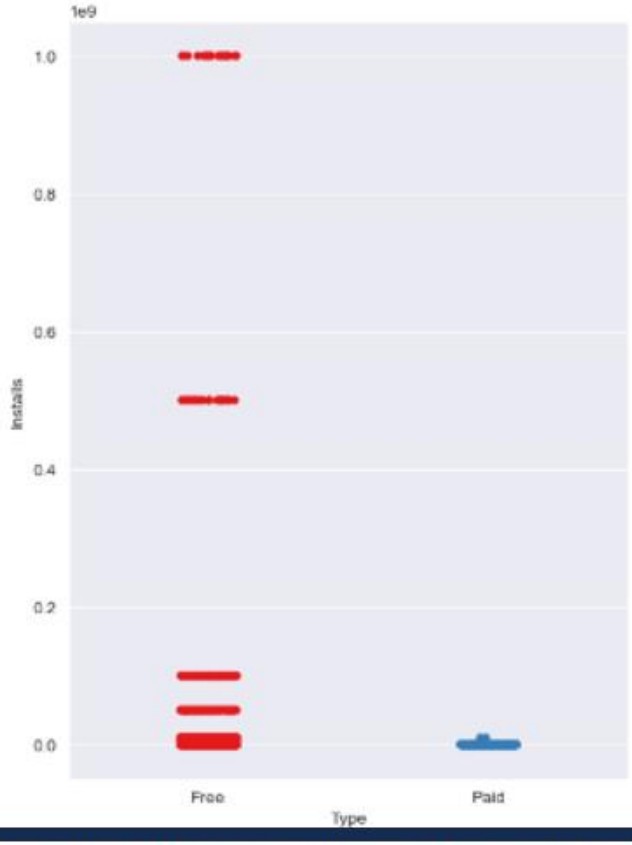

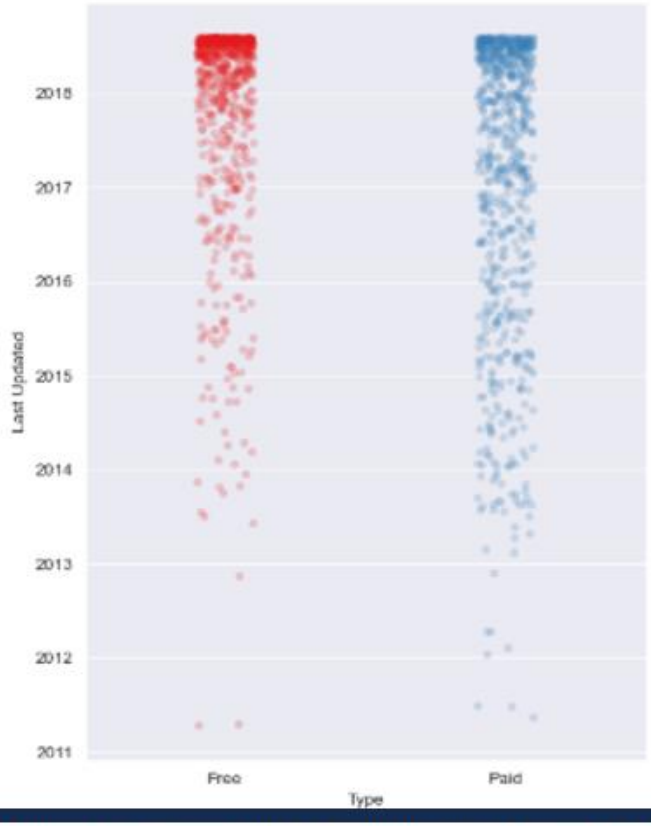

Luego de anaizar las diferentes características que nos ofrece la base de datos, entre otras de las diferencias que se pueden observar entre las aplicac iones del tipo gratuito y las de paga, son que las aplicaciones gratuitas tienen una mayor preferencia por los usuarios, ya que se observa una mayor can tidad de instalaciones. Otra observación interesante es que las aplicaciones gratuitas se actualizan con mayor frecuencia.

8. Sentiment analysis

La minería de datos de reseñas de usuarios para determinar cómo se sienten las personas acerca de su producto, marca o servicio se puede realizar mediante una técnica llamada análisis de sentimientos. Las reseñas de los usuarios de las aplicaciones se pueden analizar para identificar si el estado de ánimo es positivo, negativo o neutral con respecto a esa aplicación. Por ejemplo, las palabras positivas en la revisión de una aplicación pueden incluir palabras como "asombroso", "amigable", "bueno", "excelente" y "amor". Las palabras negativas pueden ser palabras como 'malware', 'odio', 'problema', 'reembolso' e 'incompetente'.

¿Qué podemos decir acerca del analisis de sentimiento de las aplicaciones?

```
# Carga el archivo user_reviews.csv
reviews_df = pd.read_csv("user_reviews.csv")

# Une los dos DataFrames (join)
merged_df = pd.merge(reviews_df, type_apps, on='App')

# Elimina los valores nulos (NA) de las columnas Sentiment y Review
merged_df = merged_df.dropna(subset = ['Sentiment', 'Review'])

# Grafica la polaridad de sentimientos para apps gratuitas y de paga
sns.set_style('ticks')
fig, ax = plt.subplots()
fig.set_size_inches(11, 8)

ax = sns.boxplot(x = "Type", y = "Sentiment_Polarity", data = merged_df)
ax.set_title('Sentiment Polarity Distribution')

print("¿Qué podemos decir acerca del analisis de sentimiento de las aplicaciones?", "R = De acuerdo con las gráficas de caja realizadas, la polaridad de
```

¿Qué podemos decir acerca del analisis de sentimiento de las aplicaciones? R = De acuerdo con las gráficas de caja realizadas, la polaridad de sentimiento para los casos de aplicaciones gratuitas y de paga parecen comportarse de forma similar, sin embargo, en las aplicaciones gratuitas se puede observar que existen algunas casos atípicos donde el usuario estuvo bastante descontento, mientras que en las aplicaciones de paga no se presentan estos casos de experiencias tan negativas.

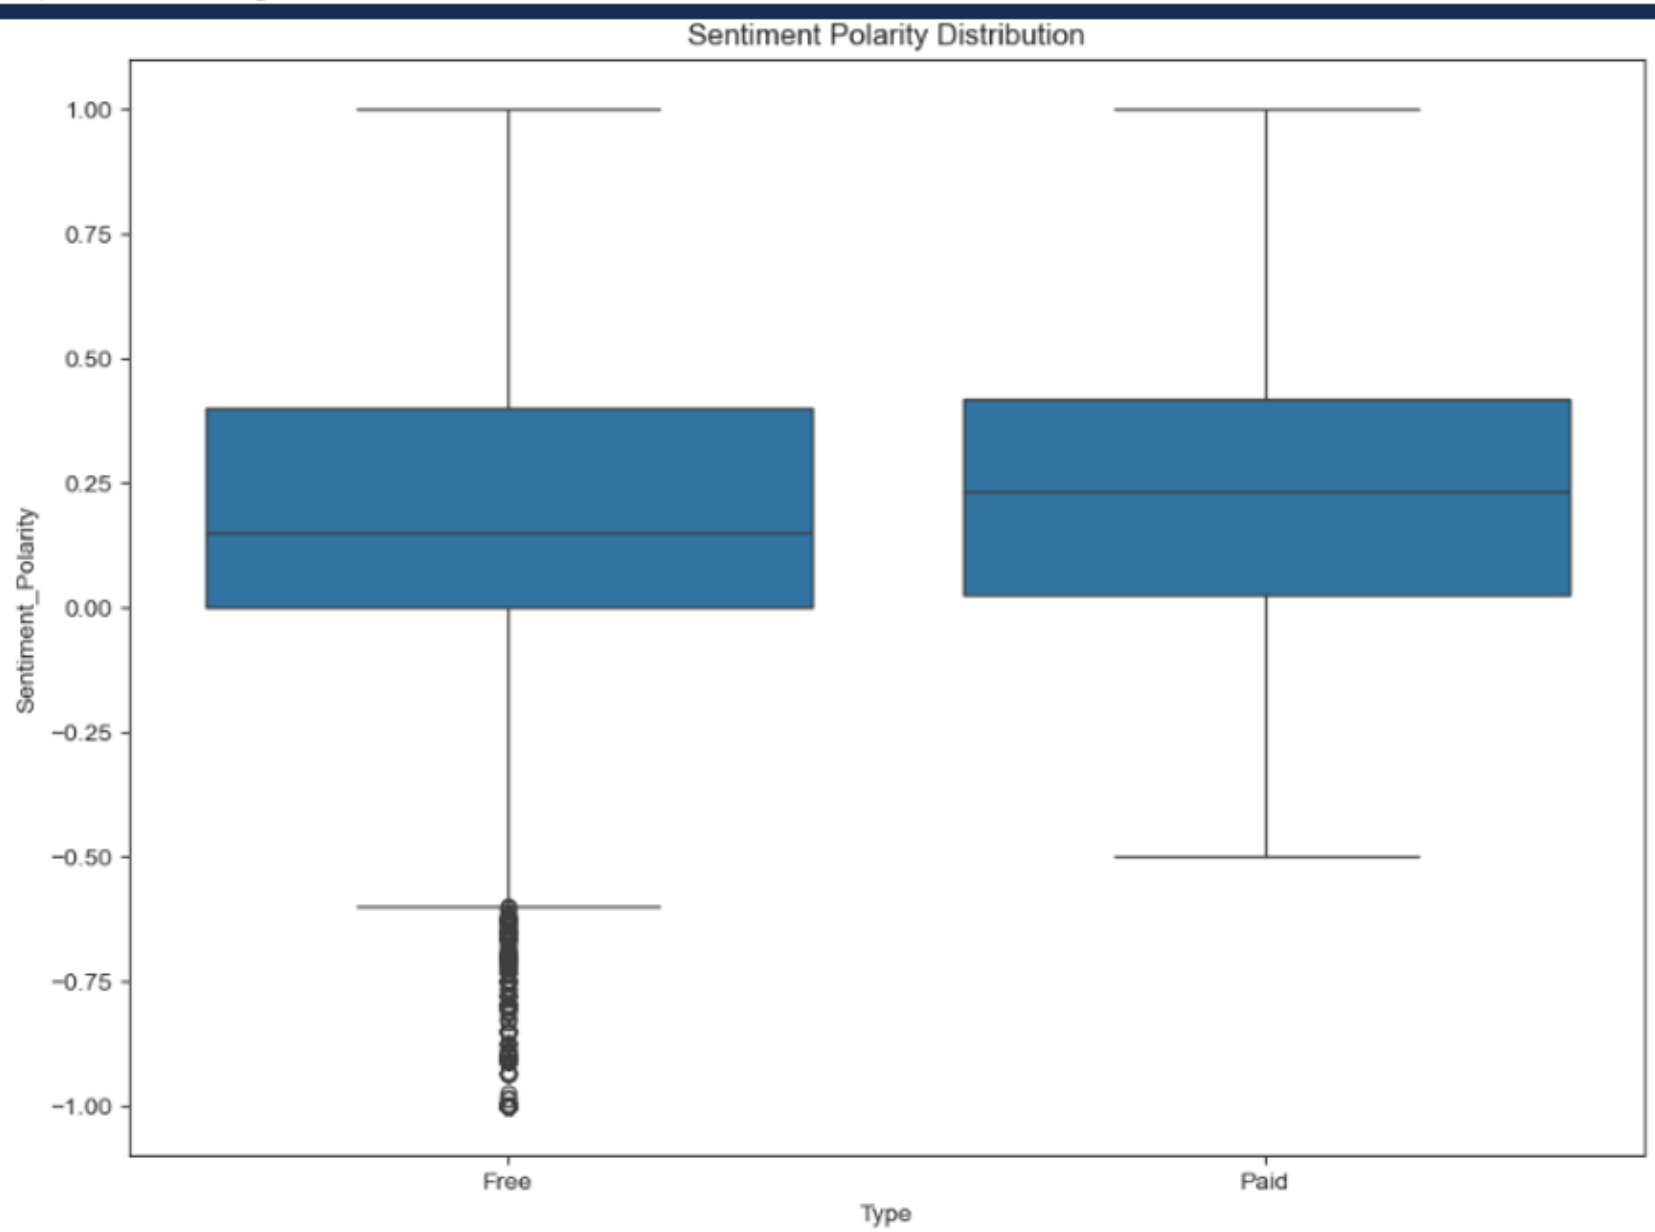

9. Conclusion

Luego del análisis descriptivo de los datos, se logró concluir sobre varias características y comportamientos que definen a las aplicaciones de algún tipo o usuarios. Entre las variables que se ingresaron al análisis y se realizaron inferencias son;

- Categorías de las aplicaciones.
- Comportamiento de la variable de calificaciones que los usuarios dan a las apps.
- Correlación entre el precio y tamaño de las apps con respecto a la calificación obtenida por los usuarios.
- Caracterícticas que diferencían a las apps del tipo gratuitas vs de paga.
- Diferencia de percepción de los usuarios de las apps gratuitas vs de paga a través de un análisis de sentimiento de las reseñas.

ESta información, puede ser de gran ayuda para el diseño, posicionamiento y rentabilidad de una aplicación, ya que la información recabada del análisis permite comprender las necesidades y preferencias de los usuarios.